Επίλυση πτοβλήματος Ταξινόμισης MNIST με χρήση MLP νευρωνικού δικτύου
Multi-Layer Perceptron Classification

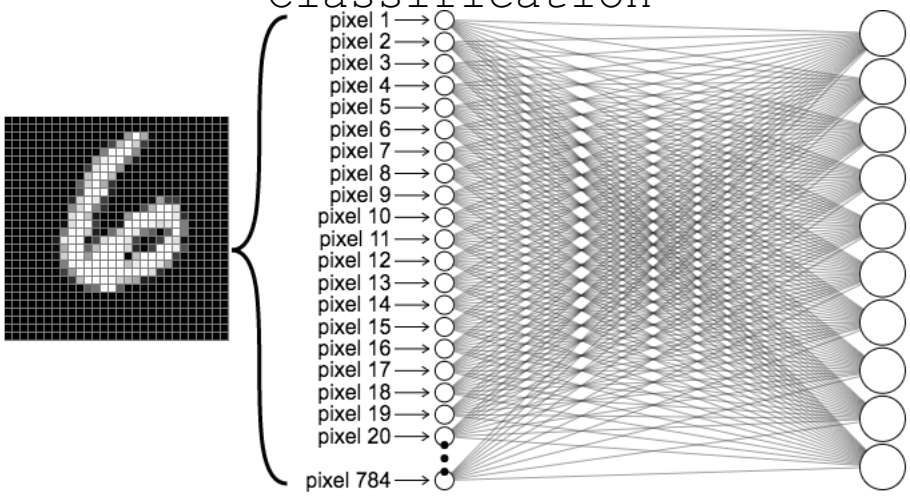

Χάρης Φίλης ΑΕΜ: 9449
Github Repository Link : here

October,2022

Contents

List of Figures

0.1 Εισαγωγή - **Abstract**

Το αντικείμενο την συγκεκριμένης εργασίας είναι ή μελέτη της λειτουργίας των πυκνών μή συνελικτικών MLP νευρωνικών δικτύων στο κομμάτι της ταξινόμησης ενός dataset χειρόγραφων αριθμών 0-9 (input layer) στις αντίστοιχες κλάσεις τους (output layer). Πιο συγκεκριμένα γίνεται διερεύνηση μεταξύ διαφορετικών αρχιτεκτονικών δικτύου, διαφορετικόν μορφών εκπαίδευσης με χρήση του αλγορίθμου back-propagation πάντα αλλά και διαφορετικού τρόπου βελτιστοποίηση βαρών του δικτύου με σκοπό την εύρεση του βέλτιστου δικτύου ως προς την μετρικής της ακρίβειας εκτίμησης της κλάσης ενός αριθμού, αλλά και άλλων μετρικών μετέπειτα με χρήση της αντικειμενικής συνάρτησης κόστους categorical cross-entropy της οποίας ο μαθηματικός τύπος φαίνεται παρακάτω.

$$J(i) = -\sum_{e=1}^{0} y_{i,e} \log_{\epsilon} \hat{y_{i,\epsilon}}$$

Στην συνέχεια εφαρμόζεται ένας αποδοτικός τρόπος αυτόματης βελτιστοποίησης των υπερπαραμέτρων του νευρωνικού δικτύου.

0.2 Διερεύνηση απόδοσης μοντέλου με διαφοροποίηση στον σχεδιασμό και την διαδικασία εκπαίδευσης

Τα μοντέλα που παρουσιάζονται στην συνέχεια έχουν δύο κρυφά layers νευρώνων. Το πρώτο αποτελείται απο 128 νευρώνες ενω το δεύτερο αποτελείται απο 256 νευρώνες. Η επιλογής της μη γραμμικότητας των νευρώνων δηλαδή η συνάρτηση ενεργοποίησης είναι η ReLU και αυτό ορίζεται εξαρχής από την εργασία πιθανόν διότι ο αλγόριθμος back-propagation χρειάζεται τα gradients των βαρών να μην είναι πολύ μικρά και να υπάρχει θέμα λόγω αυτού στην εκπαίδευση, ένα πρόβλημα που εισάγεται απο άλλες συναρτήσεις ενεργοποίησης. Τέλος εφόσον μιλάμε για πρόβλημα ταξινόμησης και συγκεκριμένα πολλών κλάσεων η συνάρτηση ενεργοποίησης του output layer είναι ή softmax που εμφανίζει ουσιαστικά πιθανότητες στην έξοδο του δικτύου και μάλιστα στους 10 νευρώνες που έχει το output layer. Τα εσωτερικά layer είναι πλήρως συνδεμένα δηλαδή πρόκειται για Dense δίκτυο και όχι συνελικτικό. Η μετρική βελτιστοποίησης είναι η ακρίβεια ή accuracy και ή αντικειμενική συνάρτηση προς βελτιστοποίηση είναι η categorical cross-entropy όπως αναφέρθηκε παραπάνω. Η εκπαίδευση διαρκεί 100 εποχές και το validation set είναι το 20% του συνολικού dataset.Τα μοντέλα πέρα αυτών των βασικών χαρακτηριστικών διαφέρουν μεταξύ τους.

0.2.1 Αλλαγή της μεθοδολογίας εκπαίδευσης του **dataset**

Σε αυτό το πρώτο κομμάτι της διερεύνησης αυτό που ουσιαστικά αλλάζει είναι ο τρόπος με τον οποίο εκπαιδεύεται το δίκτυο. Συγκεκριμένα αλλάζει το μέγεθος του **batch size** , μιας υπερπαραμέτρου του **gradient descent** η οποία ελέγχει τον αριθμό των δειγμάτων εκπαίδευσης που δουλεύει ο αλγόριθμος βελτιστοποίησης πριν το μοντέλο αναβαθμίσει τις εσωτερικές του παραμέτρους και ουσιαστικά δουλέψει ο αλγόριθμος του **back-propagation**. Να σημειωθεί ότι γίνεται χρήση **output layer** με **softmax activation** συνάρτηση επομένως κατα τον υπολογισμό του **cross-entropy loss** δεν χρειάζεται περαιτέρω κανονικοποίηση των εξόδων (logits=false) και επίσης δεν χρησιμοποιείται η **sparse cross-entropy** που διδάχθηκε στην ενισχυτική διδασκαλία για τον ίδιο λόγο. Επίσης τα δεδομένα κανονικοποιούνται στην κλίμακα 0-1 αντί για 0-256 και τέλος τα δεδομένα **test** υπόκεινται σε **one-hot encoding** ώστε να εξοικονομηθεί υπολογιστικό χρόνος μιας και πρόκειται για κατηγορικά δεδομένα ουσιαστικά. Έχω έτσι **tensors** με τιμή 1 στην κλάση που μας ενδιαφέρει.

Model 1

Το πρώτο μοντέλο είναι το βασικό μοντέλο που αναλύθηκε παραπάνω με χρήση όμως το **RMSProp optimizer** με **learning rate** = 0.001 και ρ=0.9. Επίσης το **training** που γίνεται είναι **online** που σημαίνει οτι ο αλγόριθμος βελτιστοποίησης δουλεύει όλα τα δείγματα και υπολογίζει τα **gradients** και τρέχει τον αλγόριθμο βελτιστοποίησης για να αναβαθμιστεί το δίκτυο. Αυτο σημαίνει η διάρκεια εκτέλεσης επιβαρύνθηκε και συγκεκριμένα έφτασε τις 3 ώρες. Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για **training** και **validation set** αυτού του μοντέλου.

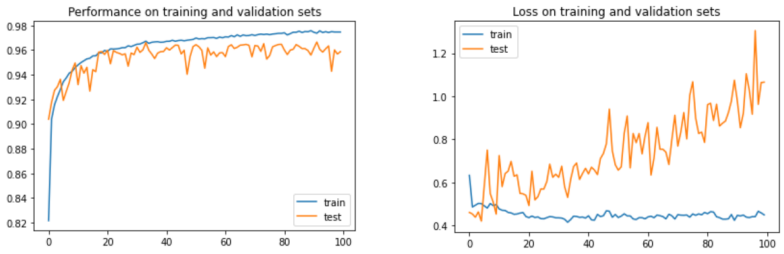

(a) Accuracy (b) Loss

Figure 1: Καμπύλες Accuracy και Loss για το μοντέλο 1

Αυτό που παρατηρώ είναι ότι το συγκεκριμένο μοντέλο πετυχαίνει μεγάλη ακρίβεια για το σύνολο εκπαίδευσης πολύ γρήγορα δηλαδή σε λίγες εποχές ενώ στο **validation set** η ακρίβεια δεν σταθεροποιείται και μάλιστα παρατηρούμε και φαινόμενο χειροτέρευσης και επαναφοράς τύπου ταλάντωσης της ακρίβειας του μοντέλου στο πέρας των εποχών χωρίς όμως αυτό να σημαίνει ότι το μοντέλο δεν

είναι αποδοτικό και στο validation set με ακρίβεια πάνω του 0.9. Από την άλλη πλευρά στο κομμάτι του κόστους φαίνεται πως και εκεί το κόστος ελαχιστοποιείται άμεσα αλλά στο validation set έχουμε αύξηση του κόστους και ουσιαστικά έχουμε άμεση ένδειξη υπερμοντελοποίησης ή overfitting κατι που σημαίνει ότι το μοντέλο αυτό αποστηθίζει τα δεδομένα εκπαίδευσης αντί ουσιαστικά να μαθαίνει να επιλύει το πρόβλημα της ταξινόμησης. Αυτό το πρόβλημα αντιμετωπίζεται με σχετικά απλό τρόπο είτε χρησιμοποιώντας dropout layers που προσδίδουν την έννοια του θορύβου στο νευρωνικό δίκτυο ώστε να μπορούμε να έχουμε ένα πιο robust training είτε κάνοντας καλύτερη κανονικοποιήση και ανακάτεμα των δεδομένων εισόδου ακόμα και cross validation data split το οποίο ίσως είναι μια καλύτερη λύση. Ο συνδυασμός των δύο μεθόδων αποτρέπει ακόμα περισσότερο την υπερμοντελοποίηση του νευρωνικού δικτύου.

Model 2 Minibatch training

Το μοντέλο αυτό είναι το default μοντέλο όπως ορίστηκε παραπάνω αλλά χρησιμοποιούμε batch εκμάθησης μεγέθους batch_size = 256. Αυτό έχει ήδη αναλυθεί πως προσφέρει σε ένα δίκτυο τόσο στο χρόνο εκτέλεσης αλλά θα δούμε και πως βοηθά το πρόβλημα του overfitting που εμφανίστηκε παραπάνω.

Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για training και validation set αυτού του μοντέλου.

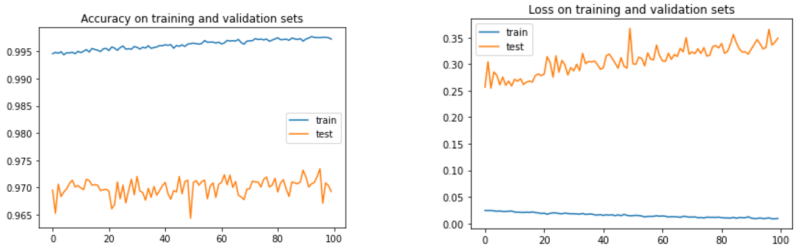

(a) Accuracy (b) Loss

Figure 2: Καμπύλες Accuracy και Loss για το μοντέλο 2

Παρατηρείται πως η απόδοση του δικτύου είναι αρκετά καλή σε επίπεδα 0.995 μάλιστα τόσο στο σύνολο εκπαίδευσης όσο και στο σύνολο επικύρωσης. Επιπλέον οι τιμές της συνάρτησης κόστους για το validation ή test set όπως φαίνεται στα υπομνήματα σταθεροποιείται (αυτό θα ήταν πιο εμφανές αν είχαμε περισσότερες εποχές). Δηλαδή δεν έχουμε διαρκή αύξηση του σφάλματος στο test set και αυτό δείχνει σημάδια ότι το μοντέλο μαθαίνει κανονικά μια και το train loss είναι κοντά στο test loss. Επομένως το μοντέλο όπως λέγεται "γενικεύει καλά". Φυσικά ο χρόνος εκπαίδευσης είναι αρκετά μικρότερος εξαιτίας ακριβώς του batch learning. Προσθέτουμε στην αντιμετώπιση του overfitting και την μέθοδο του minibatch learning.

Model 3 Batch=Ntrain

Εδώ το μοντέλο είναι ακριβώς το ίδιο με τα παραπάνω απλά το μέγεθος του batch είναι ίσο με το μέγεθος των δειγμάτων του συνόλου εκπαίδευσης. Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για training και validation set αυτού του μοντέλου. Από τα διαγράμματα παρατηρείται

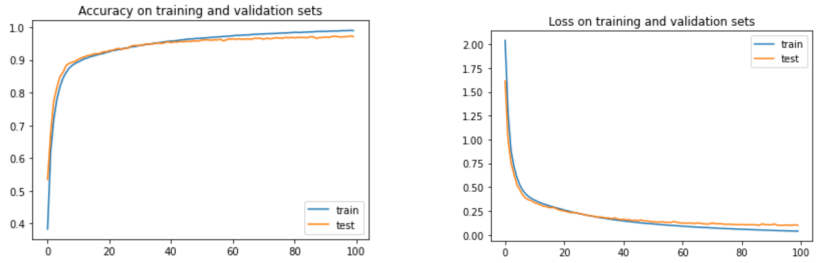

(a) Accuracy (b) Loss

Figure 3: Καμπύλες Accuracy και Loss για το μοντέλο 3

ότι μετά τις πρώτες 10 εποχές οι τιμές της ακρίβειας και του κόστους φτάνουν σταθεροποιούνται σε καλή τιμή για όλες τις επόμενες εποχές και μάλιστα οι καμπύλες κινούνται σχεδόν η μία πάνω στην άλλη. Όσον αφορά το training set φαίνεται ότι αυτό φτάνει και την απόλυτη ακρίβεια ενώ το loss οδηγείται στο μηδέν. Θα μπορούσε να διατυπωθεί ότι σε αυτό το σημείο έχουμε το τέλειο μοντέλο μιας και βλέπουμε καλή πορεία των καμπυλών. Παρόλα αυτά το γεγονός ότι μετά από τις πρώτες εποχές οι καμπύλες έχουν πολύ μικρή κλίση δείχνει ότι η εκπαίδευση δεν είναι απαραίτητη για 100 εποχές. Τέλος χρονικά το συγκεκριμένο μοντέλο ολοκληρώνει την εκπαίδευση σε 40 δευτερόλεπτα κάτι που είναι μακράν λιγότερο χρόνος εκτέλεσης εκπαίδευσης σε σχέση με τα δύο προηγούμενα μοντέλα.

0.2.2 Χρήση Διαφορετικών αλγορίθμων Βελτιστοποίησης και **Layer**

Μιας και το τελευταίο μοντέλο δεν φαίνεται να εκπαιδεύεται για περισσότερες από 10 εποχές εξακολουθεί η χρήση του μοντέλου με το minibatch training μιας και φάνηκε να είναι το μοντέλο που γενικεύει καλύτερα και είναι και εκπαιδεύσιμο.

Model 4

Για αυτό το μοντέλο χρησιμοποιήθηκε ο RMSProp με learning rate lr = 0.001 και ρ ή rho = 0.01. Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για training και validation set αυτού του μοντέλου.

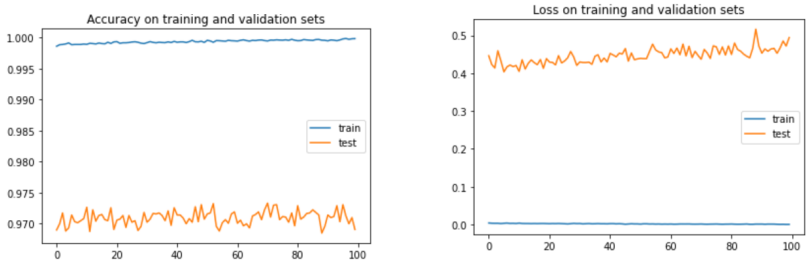

(a) Accuracy (b) Loss

Figure 4: Καμπύλες Accuracy και Loss για το μοντέλο 4

Παρατηρούμε ότι το accuracy (0.99) του training set καθώς και το loss(0.01) παρουσιάζει πολύ καλές τιμές έως άριστες ενώ το accuracy και του loss του validation set είναι και αυτά σε καλές τιμές άρα γενικεύει καλά το μοντέλο. Είναι γνωστό από την θεωρία, ότι στον RMSProp optimizer η μικρή τιμή της υπερπαραμέτρου ρ ,η οποία ελέγχει την κλίμακα του κινούμενου μέσου όρου που εφαρμόζεται στα βάρη , ευνοεί ουσιαστικά την κίνηση του αλγορίθμου προς παλιότερες διευθύνσεις του αθροιστικού τετραγωνικού gradient με αποτέλεσμα να μην υπάρχει βελτίωση αν έχει επιτευχθεί η καλύτερη μέχρι στιγμής τιμή(τωρινή εποχή) του accuracy.Για αυτό τον λόγο δεν μπορεί να κριθεί αυτή η περίπτωση ως περίπτωση overfitting ωστόσο το μικρό learning rate είναι αυτό που εγκλωβίζει σε αυτή την κατάσταση τον αλγόριθμο και κάνει την εκπαίδευση στάσιμη.

Model 5

Σε αυτό το μοντέλο ανεβαίνει το learning rate και ταυτόχρονα τοποθετούμε την παράμετρο ρ στην τι μη 0.99 που είναι πολύ κοντά στο όριο της. Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για training και validation set αυτού του μοντέλου.

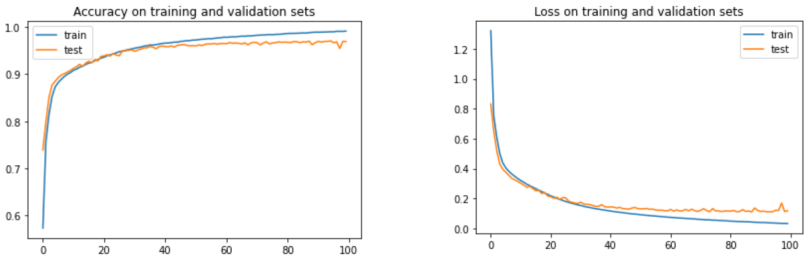

(a) Accuracy (b) Loss

Figure 5: Καμπύλες Accuracy και Loss για το μοντέλο 5

Αυτό που παρατηρώ στα δυο γραφήματα είναι ότι παρόλο που η παράμετρος ρ είναι πολύ μεγάλη που σημαίνει ότι το μοντέλο οδηγείται προς την παρούσα διεύθυνση των αθροιστικών τετραγωνικών gradient, αυτή η κατεύθυνση λόγω αύξησης του learning rate τελικά είναι σωστή και το μοντέλο αποφεύγει την προηγούμενη σκόπελο. Επομένως φαίνονται πολύ καλά learning curves αλλά και στο κομμάτι του accuracy και του loss παρόλο που στο loss ξεκινάμε από αρκετά μεγάλη τιμή.

0.2.3 Αρχικοποίηση συναπτικών βαρών με βάση κανονική κατανομή

Model 6

Το συγκεκριμένο μοντέλο πέραν του ότι χρησιμοποιείται άλλος αλγόριθμος βελτιστοποίηση και συγκεκριμένα ο Stochastic Gradient Descend με learning rate = 0.01 και default momentum = 0, εφαρμόζεται σε αυτό και αρχικοποίηση συναπτικών βαρών με χρήση kernel κανονικής κατανομής με μέση τιμή το 10. Στα παρακάτω σχήματα φαίνονται οι καμπύλες ακρίβειας και κόστους για τα training και validation sets. Αυτό που παρατηρείται στο κομμάτι της ακρίβειας (accuracy),

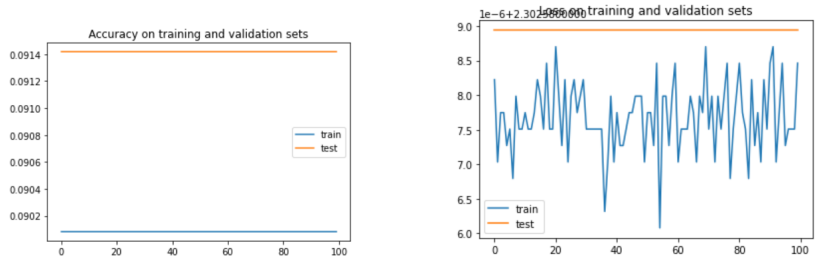

(a) Accuracy (b) Loss

Figure 6: Καμπύλες Accuracy και Loss για το μοντέλο 6

είναι πως το μοντέλο δεν προσαρμόζεται καθόλου στα δεδομένα εκπαίδευσης και φαίνεται απο το γεγονός οτι βλέπουμε μεγαλύτερη ακρίβεια στα test data παρά στα training. Έτσι στην συγκεκριμένη περίπτωση μιλάμε για underfitting. Ενδιαφέρον περίπτωση είναι αυτή του loss στο training set. Φαίνεται μια ανεξέλεγκτη πορεία και αυτό κατά πάσα πιθανότητα οφείλεται στην αρχικοποίηση των βαρών με μια κατανομή με μεγάλη μέση τιμή σε σχέση με τις τιμές των δεδομένων. Ουσιαστικά σε αυτή την περίπτωση οι αρχικές αυτές τιμές των gradients είναι τόσο μεγάλες σε σχέση με τα δεδομένα που οδηγεί σε έντονες ταλαντώσεις και αδυναμία σύγκλισης(exploding gradients). Επομένως η εισαγωγή θορύβου κατά μία έννοια στα βάρη κρίνεται μη αποτελεσματική μιας και δεν μπορούν να φτάσουν στην βέλτιστη τιμή τους μετέπειτα και το νευρωνικό δίκτυο δεν εκτελεί το task σωστά.

0.2.4 Διερεύνηση με προσθήκη Κανονικοποίησης συναπτικών Βαρών καθώς και **Layer** που αφαιρούν κόμβους **(Dropout)**

Model 7

Για το μοντέλο 7 χρησιμοποιήθηκαν οι ίδιες υπέρ-παράμετροι με το μοντέλο 6 ωστόσο εδώ εφαρμόζεται μια μορφής κανονικοποίηση στα συναπτικά βάρη με την μορφή penalty με την χρήση της L2-νόρμας δηλαδή της απόστασης ο οποίος εφαρμόζεται απευθείας στα στρώματα του δικτύου που ουσιαστικά στο keras περιβάλλον μιλάμε για τα βάρη και έχει a =0.1.Λειτουργεί μέσω αλγορίθμου Ridge Regression και αυτή η κανονικοποίηση προσθέτει την ποινή καθώς η πολυπλοκότητα του μοντέλου αυξάνεται. Η παράμετρος a μπαίνει σαν ποινή σε όλες τις παραμέτρους εκτός αν αποτρέπει την σύγκλιση του μοντέλου και τον κάνει να μην γενικεύει καλά ή να υπερμοντελοποιείται. Ο Ridge regression αλγόριθμος με τον οποίο λειτουργεί προσθέτει το τετράγωνο του a σαν ποινή στην συνάρτηση κόστους.

$$J(\theta) = \frac{1}{2m}\left[\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})^2 + \lambda\sum_{j=1}^{n}\theta_j^2\right]$$
$$\min_\theta J(\theta)$$

Figure 7: L2 Ridge Regression Reguralizer λ = a

Διαγράμματα Όπως φαίνεται από τα παραπάνω διαγράμματα, το μοντέλο αυτό εί-

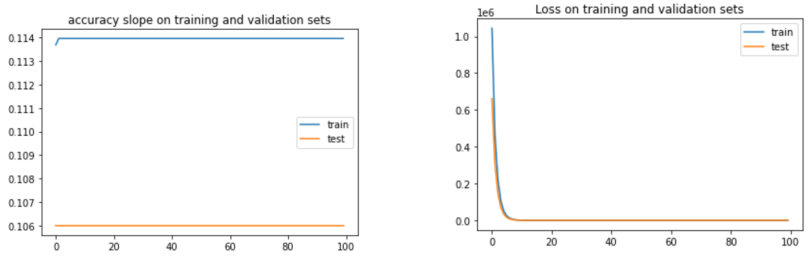

(a) Accuracy (b) Loss

Figure 8: Καμπύλες Accuracy και Loss για το μοντέλο 7

ναι αναποτελεσματικό στο να κάνει την ταξινόμηση των δεδομένων.Δεν έχουμε καμία βελτίωση καθόλη την διάρκεια της εκπαίδευσης και ειδικότερα στην συνάρτηση κόστους η αρχική τιμή είναι εξαιρετικά μεγάλη(λογικά λόγω του μεγάλου penalize μια και η αρχικοποίηση των βαρών γίνεται ουσιαστικά με θόρυβο).Παρ όλη την διόρθωσή αυτού σχετικά σε μικρό αριθμό εποχών δεν βλέπουμε το μοντέλο να βελτιώνεται παραπέρα.Επομένως καταλήγουμε σε ίδια συμπεράσματα με εξαίρεση ότι πλέον έχουμε μια σχετική βελτίωση του εξαιρετικά κακού loss.

Model 8

Σε αυτό το μοντέλο η παράμετρος a μειώνεται σε 0.01 για να περιοριστεί αυτή η ποινή. Σε αυτά τα διαγράμματα φαίνεται ότι το κομμάτι του loss πλέον φτάνει

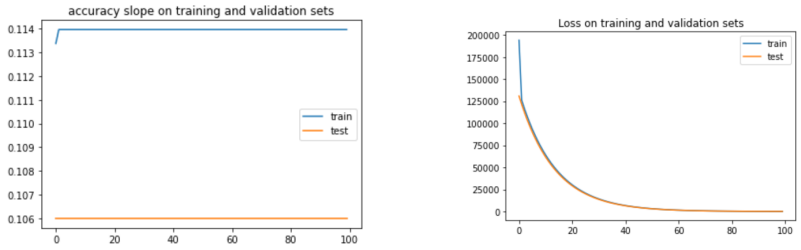

(a) Accuracy (b) Loss

Figure 9: Καμπύλες Accuracy και Loss για το μοντέλο 8

σε χαμηλότερη κλίμακα και μάλιστα συνεχίζει και αρχίζει να συγκλίνει στο 0 ακόμα από την 60η εποχή κάτι που ισχύει και για το validation και για το test set.Παρόλα αυτά, το μοντέλο συνεχίζει να μην είναι αποδοτικό καθώς η ακρίβεια εκτίμησης του παραμένει στο 0.1 χωρίς όμως να έχουμε φαινόμενα υπερμοντελοποίησης. Επομένως δεν πρόκειται για ένα καλό μοντέλο.

Model 9

Μειώνεται περαιτέρω η παράμετρος της L2 νόρμας στο a =0.001. Στα παρακάτω διαγράμματα φαίνονται οι καμπύλες ακρίβειας και κόστους για training set και validation set. Δεν βλέπουμε κάποια βελτίωση σε κανένα από τα δυο διαγράμ-

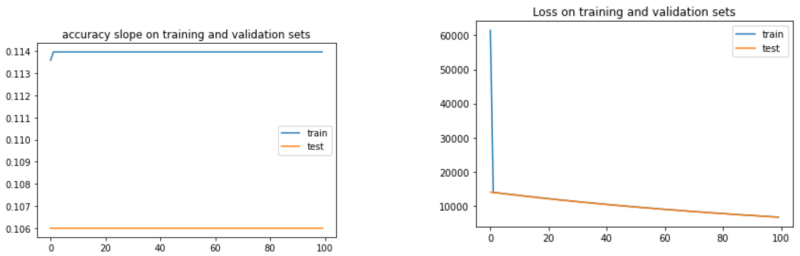

(a) Accuracy (b) Loss

Figure 10: Καμπύλες Accuracy και Loss για το μοντέλο 4

ματα και επομένως μιλάμε για underfitting μιας και εμφανίζονται όλα τα φαινόμενα των τεράστιων gradients ,των στάσιμων καμπυλών καθώς και των κακών τιμών ακρίβειας και κόστους. Σαν προσωπική σημείωση θα σημείωνα ότι η χρήση της L2 νόρμας σε συνδυασμό με τον θόρυβο στα βάρη είναι άστοχη στην συγκεκριμένη περίπτωση καθώς το δεύτερο οδηγεί σε exploding gradients και το

δεύτερο λόγω μεγάλων **gradients** οδηγεί σε συνεχόμενες ποινές που σε αυτή την περίπτωση λόγω του μικρού συντελεστή a δεν έχουν και κάποια ουσιαστική επίδραση.

Model 10

Στο συγκεκριμένο μοντέλο γίνεται στροφή στον τρόπο κανονικοποίησης μέσω της L1 νόρμα και του αντίστοιχου **reguralizer** αλγορίθμου που εφαρμόζεται(a=0.001). Επιπλέον ενσωματώνονται στην αρχιτεκτονική του δικτύου **dropout layers** τα οποία αφαιρούν νευρώνες πρακτικά με πιθανότητα 0.3. Ως μέθοδος βελτιστοποίησης χρησιμοποιήθηκε RMSprop με ρ=0,9 και l_r=0.01 Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για **training** και **validation set** αυτού του μοντέλου. Παρατηρείται και εδώ αδυναμία βελτίωσης του μοντέλου

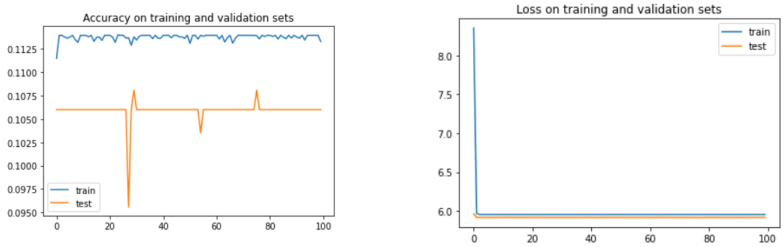

(a) Accuracy (b) Loss

Figure 11: Καμπύλες Accuracy και Loss για το μοντέλο 10

παρόλο που έχουμε βελτίωση σε σχέση με τα προηγούμενα μοντέλα ωστόσο το loss παραμένει αρκετά μεγάλο και στάσιμο και το accuracy παλινδρομεί σε πολύ χαμηλές τιμές.

0.3 Fine Tunning Υπερπαραμέτρων δικτύου

Στο προηγούμενο κομμάτι έγινε μια διερεύνηση μοντέλων για την επίλυση του προβλήματος ταξινόμησης του MNIST dataset με χρήση MLP δικτύου. Κάποια αποδείχθηκαν αρκετά αποδοτικά κάποια οδηγούνταν σε υπερμοντελοποίηση αποστηθίζοντας το dataset και κάποια σε υπόμοντελοποίηση με επιδόσεις κακές και με φαινόμενα μη εφαρμογής στα δεδομένα. Είναι σαφής λοιπόν η ανάγκη μιας πιο συστηματικής μεθόδου ρύθμισης των παραμέτρων που επηρεάζουν αυτά τα μοντέλα.

0.3.1 Παραμετρικό Δίκτυο **Model_hp**

Στο συγκεκριμένο κομμάτι θα λάβουμε ένα δίκτυο που βελτιστοποιείται με RMSProp αλγόριθμο , χρησιμοποιεί αλγόριθμο κανονικοποίησης L2, αρχικοποιεί τα βάρη με Henormalization και έχει 2 hidden layers.

Βέβαια στο κομμάτι των υπόλοιπον υπερπαραραμέτρων θα γίνει αυτόματο tunning. Αυτό θα μπορούσε να γίνει μεσω αλγορίθμου Grid Search και με cross validation 5-fold ώστε να βρεθούν οι πιο αποδοτικές παράμετροι. Βέβαια το πακέτο keras παρέχει έναν πολύ πιο γρήγορο και αποδοτικό tuner που είναι εύκολος και στην χρήση. Επομένως γίνεται μια χρήση του randomSearch tuner απλά για πειραματισμό και στην συνέχεια γίνεται χρήση του hyperband tuner.

Οι υπερπαράμετροι που πρόκειται να βελτιστοποιηθούν είναι οι εξής:

- νευρώνων 1-hidden-layer - {64,128}
- νευρώνων 2-hidden-layer - {256,512}
- παράμετρος ποινής του reguralizer a - {0.1,0.01,0.001,1e-06}
- Learning rate - {0.1,0.01,0.001}

Τέλος η μετρική που χρησιμοποιείται στο συγκεκριμένο πείραμα είναι η F-score καθώς και δημιουργείται σήμα - callback για Early Stopping του tuner μιας και ή λειτουργία του είναι επαναληπτική και δεν θέλουμε να συνεχίζει την αναβάθμισης της επιλογής βέλτιστου μοντέλου αν δεν μεγαλώνει το F1_score.

Ο Tuner έτρεξε για πάνω από 30 trials και έβγαλε τα παρακάτω αποτελέσματα με early stopping. Άρα οι βέλτιστες τιμές των υπερπαραμέτρων που επιλέχθηκαν

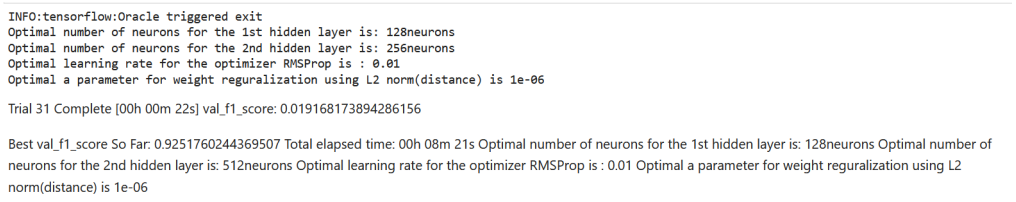

Figure 12: Keras Tuner Results

είναι:

- νευρώνων 1-hidden-layer = 128
- νευρώνων 2-hidden-layer = 256
- παράμετρος ποινής του reguralizer a = 1e-06
- Learning rate =0.01

0.3.2 Απόδοση μοντέλου

Στα επόμενα σχήματα παρουσιάζονται οι καμπύλες ακρίβειας και κόστους για training και validation set αυτού του μοντέλου.

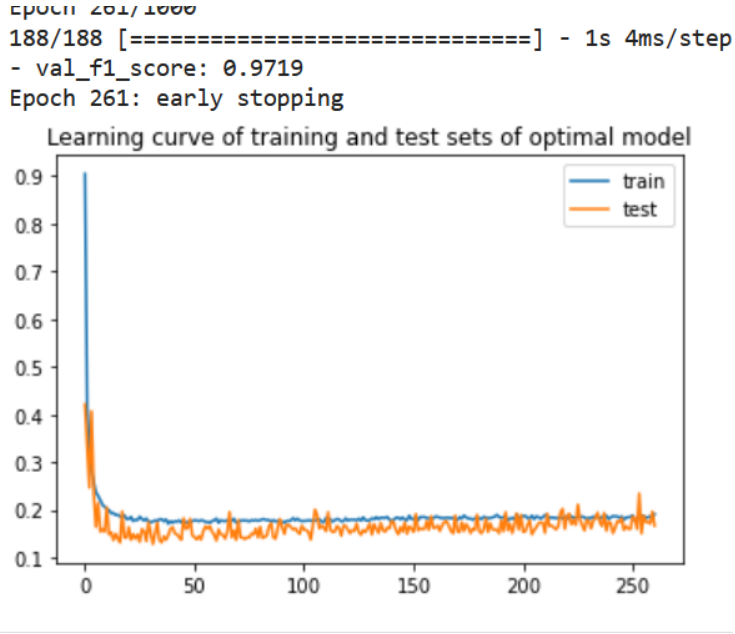

(a) Learning Curve

Figure 13: Καμπύλη μάθησης του βέλτιστου μοντέλου

Όπως μπορούμε να δούμε στο Σχ.13, οι τιμές της συνάρτησης κόστους τόσο για test όσο και για το train set είναι αρκετά μικρές και μάλιστα η καμπύλη και για τα δύο set έχει απότομη καθοδική πορεία ειδικά για το training set. Στο testing set είναι πιο ομαλή και τραχιά αυτή η μετάβαση.Φαίνεται ότι το μοντέλο φτάνει την βέλτιστη τιμή σχετικά νωρίς μόλις από τις πρώτες 20 εποχές και εδώ γίνεται αν και καθυστερημένα χρήση του σήματος early stopping για αυτό και η εκπαίδευση του δικτύου σταματά στις 250 εποχές το F1_score είναι αρκετά καλό τόσο για το validation (0.9719) set όσο και για το training set.Πιθανότατα θα έπρεπε να μειωθεί η τιμή της μεταβλητής patience ώστε να σταματήσει πιο γρήγορα το αχρείαστο training του δικτύου μιας όπως είπαμε το μοντέλο συγκλίνει και γενικεύει καλά σε λιγότερε από 50 εποχές.

Confusion Matrix

Μια άλλη μετρική που αξιολογείται στο κομμάτι αυτό είναι ο πίνακας σύγχυσης (confusion matrix)

	precision	recall	f1-score	support
0	0.97	0.99	0.98	980
1	0.98	0.99	0.98	1135
2	0.96	0.98	0.97	1032
3	0.97	0.98	0.97	1010
4	0.99	0.95	0.97	982
5	0.98	0.96	0.97	892
6	0.97	0.98	0.98	958
7	0.97	0.97	0.97	1028
8	0.97	0.96	0.96	974
9	0.97	0.96	0.96	1009
accuracy			0.97	10000
macro avg	0.97	0.97	0.97	10000
weighted avg	0.97	0.97	0.97	10000

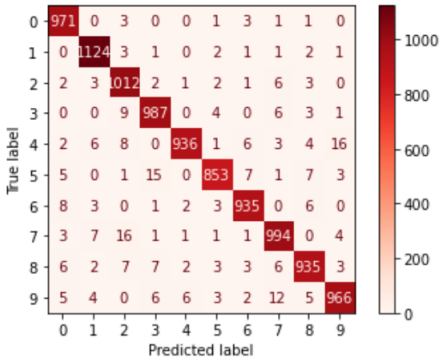

Figure 14: Πίνακας σύγχυσης για πρόβλεψη στο test set και άλλες μετρικές μοντέλου Ταξινόμησης

Στο κομμάτι του πίνακα σύγχυσης τα στοιχεία συγκεντρώνονται στην κύρια διαγώνιο κατά κύρια πλειοψηφία με ορισμένες περιπτώσεις όπως το 4 που ταξινομείται για 9 16 φορές κάτι που είναι λογικό δεδομένου ότι τα δύο νούμερα έχουν παρόμοια δομή και λογικά καταλαμβάνουν παραπλήσια pixel στο cmap. Επίσης το ίδιο συμβαίνει με το 5 και το 3 αλλά και το 7 και το 2. Ωστόσο κατά την κύρια πλειοψηφία το μοντέλο είναι άριστο.

Όσον αφορά τις κλασσικές μετρικές που παρέχει η sklearn για την ταξινόμηση, accuracy, precission ,recall, F1-score όπου: μπορούμε να δούμε ότι

$$F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

Figure 15: F1-SCORE

φτάνει το 0.97-0.98 που είναι αρκετά καλή τιμή για την ταξινόμηση του MNIST.

Τέλος γίνεται εκτίμηση 9 αριθμών στο **notebook** για πειραματισμό με το δίκτυο. Αλγόριθμοι **RandomSearch** τοποθετήθηκαν στο τέλος επίσης υπάρχουν πειραματικά και κελιά στα οποία πειραματίστηκα με το χτίσιμο μοντέλων χωρίς το **keras** με βάση τις σημειώσεις τα οποία δεν χρησιμοποιήθηκαν λόγω του ότι το **keras** περιέχει πολύ πιο βελτιστοποιημένους αλγορίθμους.